

ITESO, Universidad Jesuita de Guadalajara
Laboratorio de Desarrollo de Soluciones Tecnológicas

Beyond Fraud Detection: Uncovering Anomalous Financial Behavior Through Unsupervised Learning

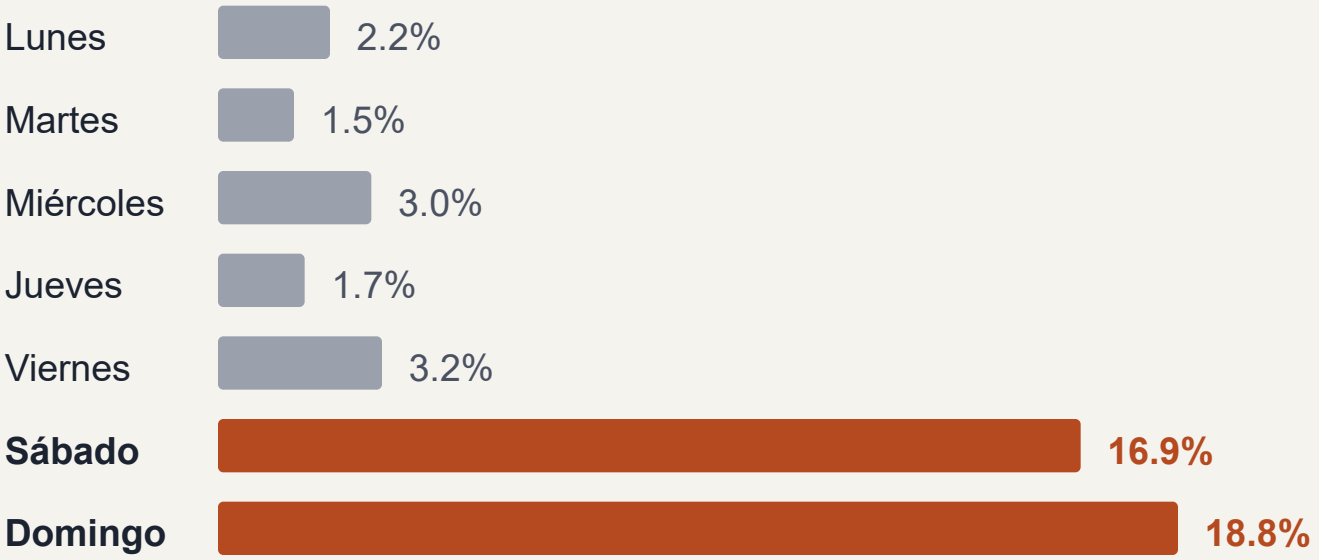
Resultados del modelo

José Armando Melchor Soto · Rolando Fortanell Canedo
Emiliano Contreras Huerta · Ismael Téllez Antillón

Octubre 2026

DÍAS DE LA SEMANA

Sábado y domingo concentran lo inusual



% de transacciones marcadas como inusuales, por día

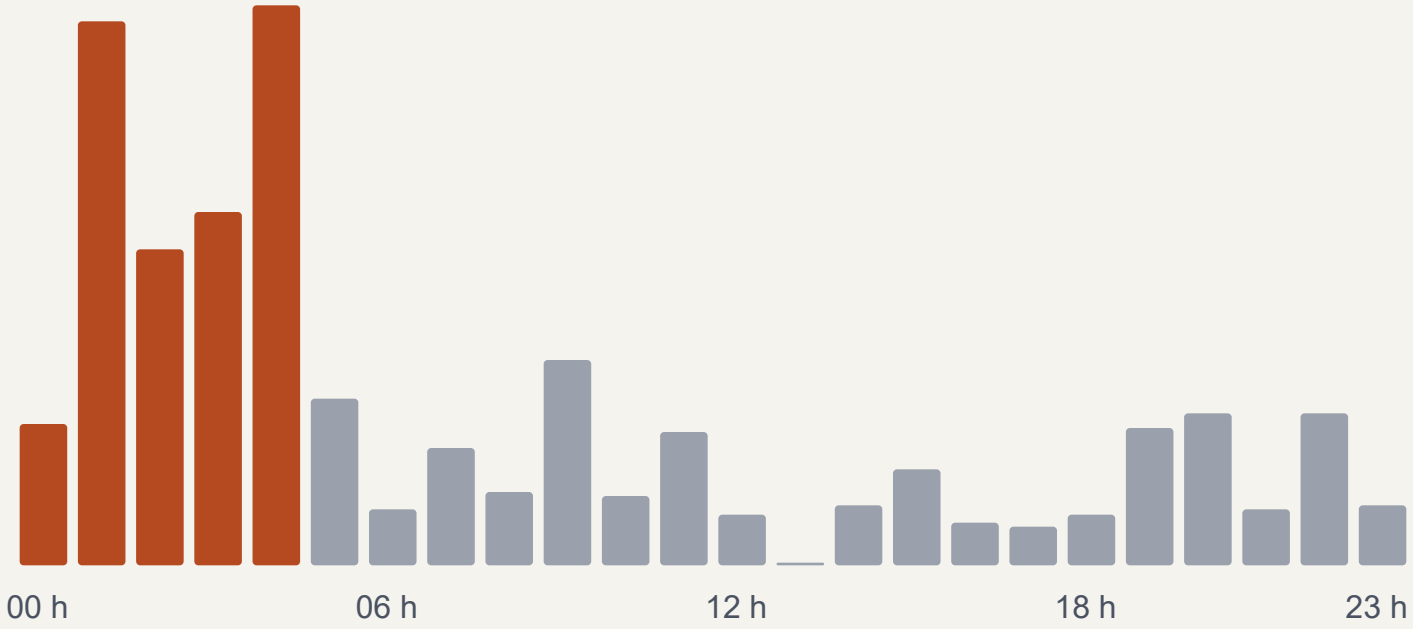
De acuerdo con el reporte de Stripe (Woodward, 2017), el fraude aumenta en los días **tranquilos**, con poca actividad legítima, y no en los de más compras.

En nuestros datos el fin de semana es justo el periodo más tranquilo: solo 214 de 3,293 transacciones (6.5%).

Fuentes: resultados del modelo (datos completos); Woodward, 2017 (Digital Transactions, reporte de Stripe); Liu et al., 2008

HORAS DEL DÍA

La madrugada se marca 8 veces más



% marcadas por hora · 00–04 h: **19.2%** · 06–23 h: **2.4%**

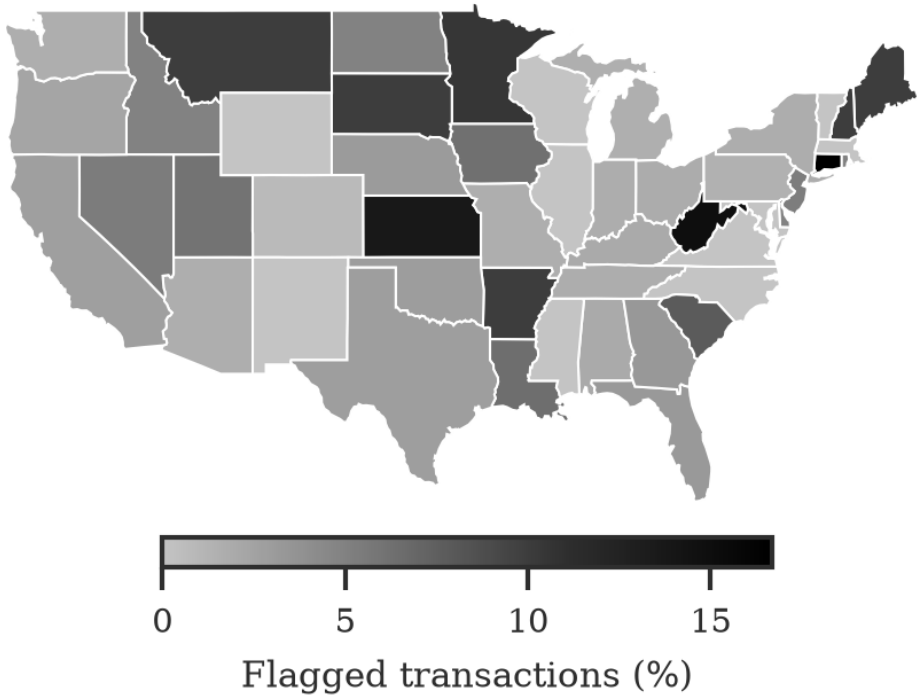
De acuerdo con Afriyie et al. (2023), el fraude con tarjeta se concentró entre las **22:00 y las 04:00**.

Accertify (2026) reporta que, de 2021 a 2025, la tasa de fraude nocturna fue en promedio **2.1 veces** la de mediodía.

Fuentes: resultados del modelo; Afriyie et al., 2023 (Decision Analytics Journal); Accertify, 2026; Woodward, 2017

ESTADOS

Dónde se marcan más transacciones



Tasas más altas

1. Connecticut	16.7%
2. Alaska	15.0%
3. West Virginia	15.0%
4. Kansas	13.8%
5. Minnesota	10.5%

Los estados más grandes quedan cerca del 2% esperado: Texas 2.9% y California 2.8%.

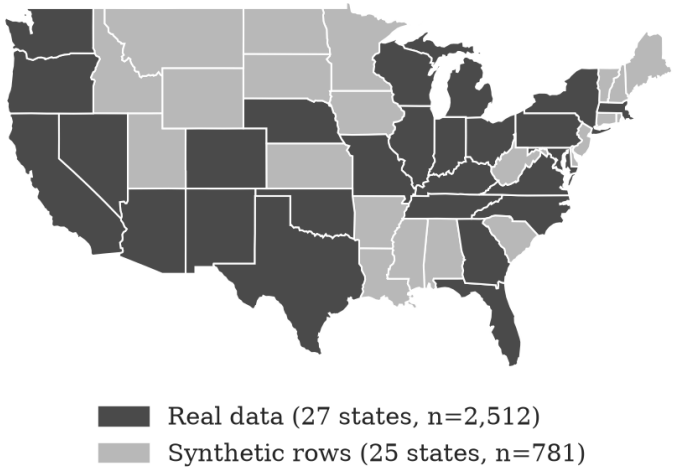
Fuente: resultados del modelo, datos completos (mínimo 15 transacciones por estado; Alaska, Hawái y Puerto Rico no aparecen en el mapa)

ESTADOS

Las tasas extremas vienen de muestras chicas

Estado	Transacciones	Tasa	Datos
Connecticut	36	16.7%	Sintéticos
Alaska	20	15.0%	Sintéticos
West Virginia	20	15.0%	Sintéticos
Kansas	29	13.8%	Sintéticos
Minnesota	57	10.5%	Sintéticos
Texas	346	2.9%	Reales
California	357	2.8%	Reales

De acuerdo con Wainer (2007), las tasas de grupos pequeños varían mucho más: los valores extremos de un mapa suelen caer en las áreas más chicas.



Los **12 estados** con tasas más altas solo tienen filas sintéticas, agregadas para que el mapa cubriera todo el país. Sintéticas: 7.3% marcadas; reales: 2.0%.

Fuentes: resultados del modelo; Wainer, 2007 (American Scientist); Jordon et al., 2022

VARIABLES

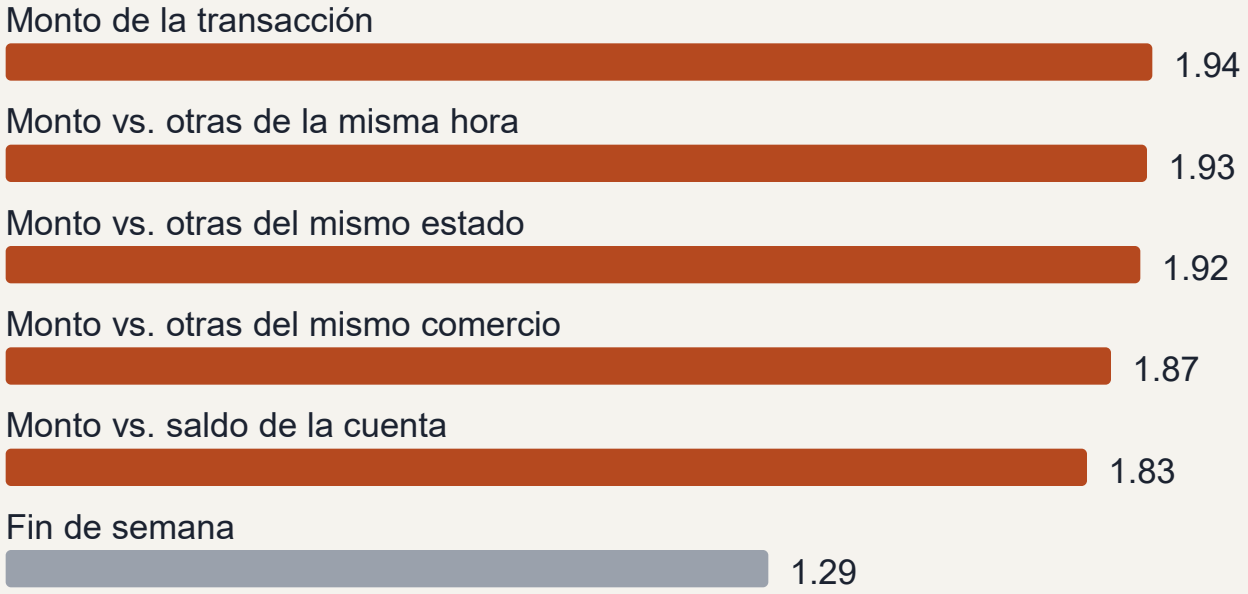
El monto es la señal más fuerte

$878

monto promedio de las marcadas, contra **$273** de las normales

Whitrow et al. (2009) mostraron que resumir el comportamiento reciente de cada cliente mejora la detección de fraude. Correa Bahnsen et al. (2016) compararon cada transacción con las anteriores del cliente, igual que nuestras variables de contexto.

Diferencia entre marcadas y normales



Diferencia de promedios, en desviaciones estándar (periodo de prueba)

Fuentes: resultados del modelo; Whitrow et al., 2009 (Data Min. Knowl. Discov.); Correa Bahnsen et al., 2016 (Expert Syst. Appl.)

VARIABLES

Las 10 variables con más peso en el modelo



Promedio del valor SHAP absoluto · oscuro: tiempo, ubicación y tipo · naranja: monto · gris: perfil

SHAP (Lundberg y Lee, 2017) reparte el puntaje del modelo entre sus variables; su versión para árboles (Lundberg et al., 2020) lo calcula con eficiencia.

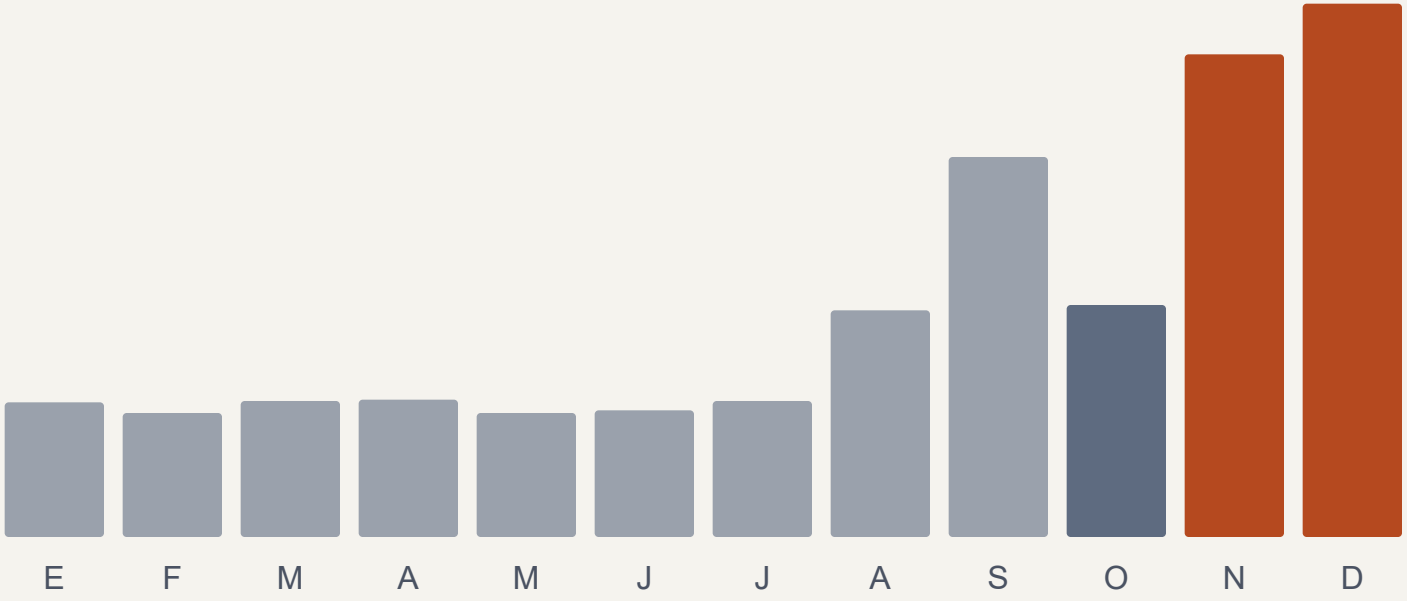
Ninguna variable domina: la más alta pesa 0.147 y el peso se reparte entre cinco tipos.

El mes va primero porque los meses de prueba vienen después de los de entrenamiento.

Fuentes: resultados del modelo (SHAP sobre 560 transacciones de prueba); Lundberg y Lee, 2017; Lundberg et al., 2020

CAMBIO EN EL TIEMPO

Desde agosto, cada mes se marca más



% marcadas por mes de 2023 · gris: entrenamiento · azul: validación · naranja: prueba

Entren.	Valid.	Prueba
2.0%	2.3%	6.8%

De acuerdo con Dal Pozzolo et al. (2018), los hábitos de los clientes y las estrategias de fraude cambian con el tiempo (*concept drift*); Gama et al. (2014) explican que los modelos fijos deben actualizarse.

Fuentes: resultados del modelo; Dal Pozzolo et al., 2018 (IEEE TNNLS); Gama et al., 2014 (ACM Comput. Surv.)

SUSTENTO

Cada resultado, con su fuente

Nuestro resultado	Coincide con
La madrugada (00–04 h) se marca 8 veces más	Afriyie et al., 2023; Accertify, 2026
El fin de semana se marca casi 8 veces más	Woodward, 2017 (reporte de Stripe)
Lo marcado es un monto grande para su contexto	Whitrow et al., 2009; Correa Bahnsen et al., 2016
La tasa sube de 2% a 6.8% con el tiempo	Dal Pozzolo et al., 2018; Gama et al., 2014
El orden es más estable que la lista marcada	Kalousis et al., 2007; Hariri et al., 2021
Estados con pocos datos dan tasas extremas	Wainer, 2007
Las filas sintéticas se marcan más	Jordon et al., 2022

Las fuentes hablan de fraude real; nuestro modelo marca transacciones inusuales. La coincidencia hace creíbles los patrones, pero no los confirma como fraude.

BIBLIOGRAFÍA (1/2)

Referencias

Accertify. (2026, 8 de septiembre). *Cyber Week fraud trends: 5 seasons of retail data*. https://www.accertify.com/resource/5-seasons-retail-data-shows-how-cyber-week-has-changed/

Afriyie, J. K., Tawiah, K., Pels, W. A., Addai-Henne, S., Dwamena, H. A., Owiredu, E. O., Ayeh, S. A., & Eshun, J. (2023). A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions. *Decision Analytics Journal, 6*, 100163.

Correa Bahnsen, A., Aouada, D., Stojanovic, A., & Ottersten, B. (2016). Feature engineering strategies for credit card fraud detection. *Expert Systems with Applications, 51*, 134–142.

Dal Pozzolo, A., Boracchi, G., Caelen, O., Alippi, C., & Bontempi, G. (2018). Credit card fraud detection: A realistic modeling and a novel learning strategy. *IEEE Transactions on Neural Networks and Learning Systems, 29*(8), 3784–3797.

Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys, 46*(4), 44.

Hariri, S., Carrasco Kind, M., & Brunner, R. J. (2021). Extended Isolation Forest. *IEEE Transactions on Knowledge and Data Engineering, 33*(4), 1479–1489.

Jordon, J., Szpruch, L., Houssiau, F., Bottarelli, M., Cherubin, G., Maple, C., Cohen, S. N., & Weller, A. (2022). *Synthetic data – what, why and how?* arXiv:2205.03257.

BIBLIOGRAFÍA (2/2)

Referencias

Kalousis, A., Prados, J., & Hilario, M. (2007). Stability of feature selection algorithms: A study on high-dimensional spaces. *Knowledge and Information Systems, 12*(1), 95–116.

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. En *Proceedings of the IEEE International Conference on Data Mining (ICDM)* (pp. 413–422).

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems 30* (pp. 4765–4774).

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence, 2*(1), 56–67.

Wainer, H. (2007). The most dangerous equation. *American Scientist, 95*(3), 249–256.

Whitrow, C., Hand, D. J., Juszczak, P., Weston, D., & Adams, N. M. (2009). Transaction aggregation as a strategy for credit card fraud detection. *Data Mining and Knowledge Discovery, 18*(1), 30–55.

Woodward, K. (2017, 14 de diciembre). Quiet online shopping days yield the biggest fraud spikes, Stripe says. *Digital Transactions*. https://www.digitaltransactions.net/?p=21420



ITESO, Universidad Jesuita de Guadalajara

Gracias

¿Preguntas?

José Armando Melchor Soto · Rolando Fortanell Canedo
Emiliano Contreras Huerta · Ismael Téllez Antillón